ADA 1.3 : où on en est, et où ça peut aller

Instantané du 3 novembre 2026 · modèle ADA 1.3 après la nuit d'entraînement (16 couches croisées, 124 pas du test 3) comparé à Ornith-1.5-9B (version Test01 4/8 bits) · mesures faites en local sur le Mac

En bref

- **Ce qui a progressé :** la perplexité sur le jeu EVAL est passée de 53 (départ) à 19,7 ; sur VAL (jeu plus dur) de 140,6 à 31,6. Ornith est à 5,8 et 5,4.
- **Accord avec Ornith :** ADA choisit le même mot suivant qu'Ornith dans 54 % des cas sur EVAL et 45 % sur VAL.
- **Mini-banc de code (12 fonctions courtes, jouet) :** Ornith 12/12, ADA 5/12.
- **Contexte long (le point faible) :** Ornith retrouve un passage répété 2 000 à 32 000 jetons plus tôt (perte 0,006 à 0,25) ; ADA à peine (perte 3,0 à 4,3 contre 3,5 à 4,3 pour un texte neuf : un début de copie à 2 000-4 000 jetons, rien à 8 000 et au-delà). Sur l'aiguille, ADA garde un faible rappel à 512 jetons (≈ 8 % de celui d'Ornith) qui disparaît au-delà de 4 000. Normal : l'entraînement n'a vu que des fenêtres de 512 jetons.
- **Mémoire à 1 million de jetons :** le cache d'ADA pèse 1,1 Go contre 30,5 Go pour Ornith (28 fois moins) : c'est l'intérêt de l'architecture. Il reste à prouver qu'ADA sait s'en servir.
- **Prévision honnête :** avec le débit actuel du Mac seul (20 jetons/s), la perplexité EVAL devrait atteindre environ 10 à 15 d'ici fin 2026 ; arriver près d'Ornith (6 à 7) demande beaucoup plus de calcul (location de GPU). Ce sont des extrapolations, pas des mesures.

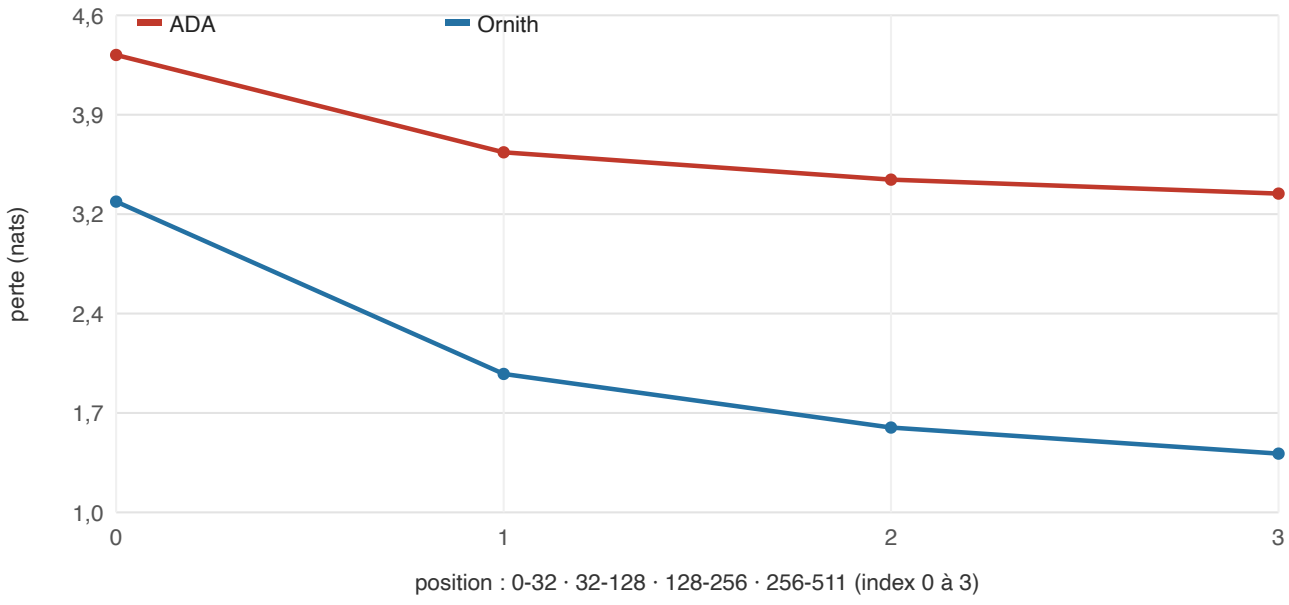
1. Qualité de prédiction (perplexité)

Plus la perplexité est basse, mieux le modèle prédit le texte. Textes de 512 jetons, jamais utilisés pour l'entraînement (code Python, JS, C++, anglais, français). La KL mesure l'écart de distribution avec Ornith (0 = identique).

Jeu	ADA	Ornith	Écart	Même mot que Ornith	KL (nats)	Textes
EVAL	19,7	5,8	3,4 ×	54 %	1,41	12
EVAL2	18,4	5,3	3,5 ×	52 %	1,41	12
VAL	31,6	5,4	5,8 ×	45 %	1,94	36

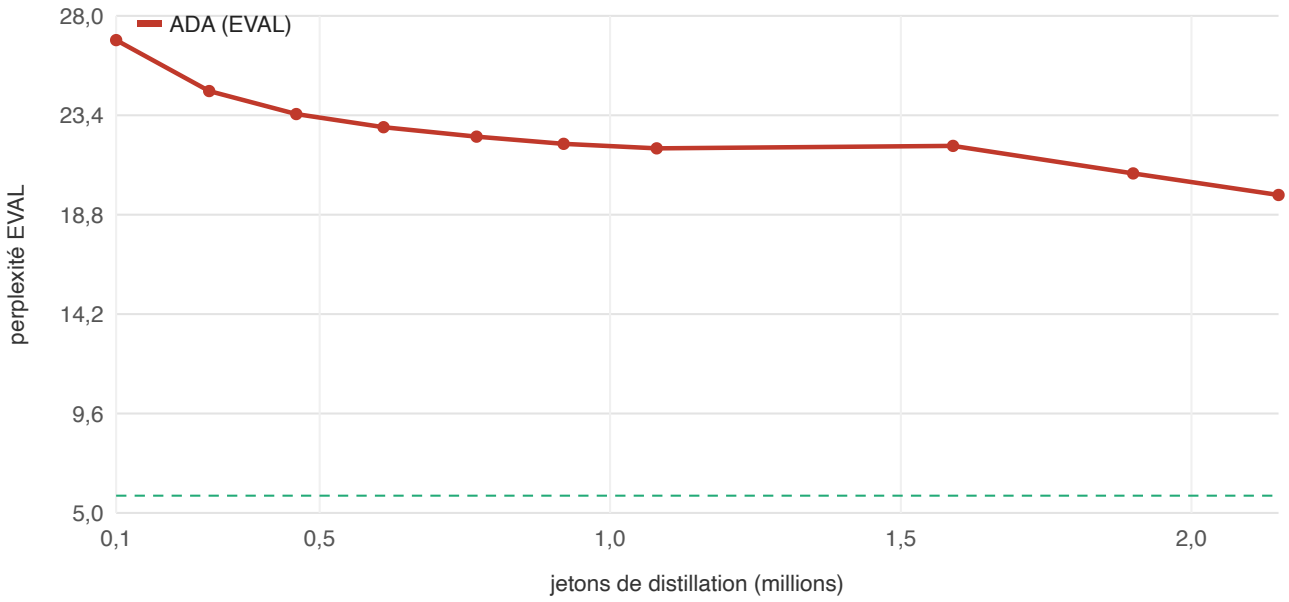
La perte selon la position dans le texte (jeu VAL)

Un modèle qui lit son contexte voit sa perte baisser quand le texte avance. Ornith passe de 3,25 à 1,43 ; ADA de 4,31 à 3,31 : il en tire encore bien moins.



2. Ce que l'entraînement a donné

Perplexité EVAL en fonction du nombre de jetons de distillation vus par la lignée principale (en millions). Les gains viennent surtout de la correction d'un bogue de sauvegarde (qui faisait croire à un plafond), de l'entraînement des 16 couches croisées et d'un taux d'apprentissage plus bas.



Ligne verte : Ornith (5,8). Tests écartés en route : perte avec alpha 0,7 (EVAL 22,5, moins bon) et 0,97 (19,98 contre 19,71, moins bon).

3. Retrouver un passage lu plus tôt (copie à distance)

Un passage de 512 jetons est répété après du texte de remplissage. On mesure la perte (en nats par jeton) sur la 2e occurrence. Un modèle qui lit son contexte long tombe vers 0 ; sinon il reste à la perte d'un texte neuf (colonne « témoin »).

Longueur totale (jetons)	Perte ADA	Perte Ornith	Témoin ADA (texte neuf)	Temps ADA / Ornith	Mémoire pic ADA / Ornith
2048	2,11	0,01	1,76	11 s / 11 s	8,5 / 8,5 Go
4096	3,29	0,01	·	22 s / 22 s	8,6 / 8,7 Go
8192	4,69	0,25	·	46 s / 46 s	8,8 / 8,8 Go
16384	4,35	0,01	3,41	103 s / 106 s	9,3 / 9,3 Go
32768	5,58	0,01	·	258 s / 231 s	11,2 / 11,2 Go

Moyenne sur 3 passages (plus fiable)

Longueur totale	ADA : 2e occurrence	ADA : texte neuf	Ornith : 2e occurrence	Ornith : texte neuf
2048	3,03	3,49	0,06	1,38
4096	3,38	3,85	0,16	2,20
8192	4,29	4,34	0,02	1,94

Si ADA lisait son contexte, la colonne « 2e occurrence » serait nettement sous « texte neuf », comme chez Ornith. Chez ADA l'écart est faible : environ 0,5 nat de mieux à 2 000 et 4 000 jetons (un début de copie), plus rien à 8 000 ; sur 32 000 jetons sa perte monte même (5,6) : il se dégrade avec la longueur.

4. Aiguille dans une botte de foin

Une liste « clé: valeur » ; on redemande 5 clés à la fin. Gain = log-probabilité de la bonne valeur avec le fait dans le contexte moins la même chose dans un contexte où le fait est remplacé (nats, somme sur les 5 clés ; plus haut = meilleur rappel ; 0 = aucun rappel ; le bruit est d'environ ±2). 3 listes par longueur. Ornith plafonne vers 78 : les valeurs sont des chaînes aléatoires, qu'on ne peut deviner qu'en les lisant.

Longueur (jetons)	Gain ADA	Gain Ornith
512	6,5	77,6
1024	2,7	77,0
2048	2,9	81,3
4096	0,6	80,3
8192	1,5	79,7

5. Mini-banc de code (jouet)

12 fonctions d'une ligne, écrites pour l'occasion, vérifiées par un test automatique. Génération gloutonne. Ce n'est pas HumanEval : un point de repère, pas un classement.

Fonction	Ornith	Complétion Ornith	ADA	Complétion ADA
add	✓	a + b	✗	a, b
is_even	✓	n % 2 == 0	✗	n % 2 == 2
square	✓	x * x	✓	x*x
last	✓	xs[-1]	✓	xs[-1]
maxi	✓	a if a > b else b	✓	max(a, b)
rev	✓	s[::-1]	✗	rev(s)
count_a	✓	s.count("a")	✗	len(s)
double_all	✓	[x * 2 for x in xs]	✗	xs.copy()
abs_val	✓	x if x >= 0 else -x	✓	abs(x)
total	✓	sum(xs)	✓	sum(xs)
first_word	✓	s.split()[0]	✗	s
is_pal	✓	s == s[::-1]	✗	s == s[::-1

Total : Ornith 12/12, ADA 5/12. Une complétion d'ADA est tronquée par la règle d'arrêt du banc (« is_pal »), donc le score ADA est peut-être sous-estimé d'un point.

6. Contexte d'un million de jetons : la mémoire (calculée)

Mémoire de cache par jeton, en bf16. Ornith : 8 couches d'attention complète, 4 têtes de clés/valeurs de dimension 256. ADA : un seul latent partagé de 512 + 64 valeurs, lu par les 16 couches croisées. Les couches récurrentes ajoutent une mémoire fixe (quelques dizaines de Mo) pour les deux.

Modèle	Octets par jeton	Go à 32 k	Go à 262 k	Go à 1 M
Ornith	32 768	0,98	8,0	30,5
ADA	1 152	0,03	0,3	1,1

Ornith consomme **28 fois plus** de cache. À 1 million de jetons, ADA tiendrait dans 1,1 Go ; Ornith ne tient pas dans un Mac de 16 Go. **Limite :** 1 million de jetons n'a pas été exécuté ici (le code d'entraînement MLX relit toute la séquence et la mémoire du

Mac ne suffirait pas) ; c'est un calcul, pas une mesure. Lire un tel cache demande en plus l'« absorption » MLA, non implémentée dans ce banc.

7. Prévisions jusqu'à fin 2026 (extrapolations)

Méthode : la perplexité EVAL est ramenée à un plancher voisin d'Ornith (6), et l'écart se réduit selon une loi de puissance du nombre de jetons vus. Trois pentes : prudente (0,10), centrale (0,20), optimiste (0,35), encadrant ce qu'on a observé (0,10 pendant la phase longue à un seul réglage ; 0,36 sur la dernière phase). La colonne VAL multiplie par 1,6 (écart observé entre les deux jeux).

Scénario	EVAL (optimiste à prudent)	EVAL (central)	VAL équivalent
Mac seul jusqu'au 31 décembre (≈ 100 M de jetons)	9,6 à 15,3	≈ 12,4	15,4 à 24,5
GPU loué, 50 fois plus de calcul (≈ 5 milliards de jetons)	6,9 à 12,3	≈ 8,9	11,0 à 19,7
GPU loué, 500 fois plus (≈ 50 milliards)	6,4 à 11,0	≈ 7,8	10,2 à 17,6

Ces chiffres supposent que le rythme de progression se maintient, ce qui n'est pas garanti : les gains ont déjà ralenti en fin de test 3 (–0,09 sur les 24 derniers pas contre –0,3 sur les 25 précédents), et une nouvelle idée peut aussi relancer la courbe. Les pistes à tester ensuite : apprendre la projection du cache partagé (test en cours), régler la perte intermédiaire, entraîner l'indexeur, des séquences plus longues, plus de calcul.

8. Ce qu'on peut raisonnablement attendre d'ici fin 2026 (hypothèses)

- **Perplexité :** voir la section 7 ; la fourchette dépend surtout du calcul disponible, pas d'une nouvelle astuce.
- **Contexte long :** la perplexité seule ne le fera pas apparaître. Il faut entraîner sur des séquences de 2 000 puis 8 000 jetons et mêler des tâches de rappel (copie, aiguille) : c'est le plan en 9 étapes (étapes 4 et 5). Hypothèse : un premier rappel net à 2 000-8 000 jetons est atteignable d'ici fin 2026 ; 32 000 jetons et au-delà est incertain ; 1 million n'est pas démontré et ne l'a jamais été sur ce Mac.
- **Code :** le mini-banc passe de 5/12 aujourd'hui vers 8-10/12 si la perplexité EVAL atteint 12-15 (hypothèse, non mesurée : le lien entre perplexité et réussite est approximatif).
- **Indexeur (sélection des passages) :** non entraîné aujourd'hui ; il ne servira qu'une fois les séquences longues en place (étape 6).
- **Pas de GPU loué prévu pour le moment** : les scénarios avec GPU de la section 7 servent seulement à mesurer l'écart.

Limites de ce rapport

- Un seul modèle (instantané du 3 nov), une seule exécution par mesure, petits échantillons (12 à 36 textes ; 3 listes d'aiguilles par longueur ; 12 fonctions de code).
- La perplexité d'ADA est mesurée sur les mêmes types de texte que l'entraînement (code et web éducatif) ; le jeu VAL, plus dur, montre moins de généralisation.
- Les prévisions sont des extrapolations avec une forte incertitude. Le test avec projection du cache apprise (Wc, Wr) n'a pas eu lieu aujourd'hui (interrompu pour ces mesures).